

Syrian Arab Republic
Ministry of Higher
Education and scientific
research
Syrian Virtual University



الجمهورية العربية السورية
وزارة التعليم العالي والبحث العلمي
الجامعة الافتراضية السورية

نظام تنبؤ بالطقس باستخدام التعلم الآلي

Weather forecasting system using machine learning

بحث مقدم لنيل درجة الماجستير في علوم الحاسب

إعداد الطالب المهندس: معلا محمود نوت

إشراف الدكتور: عصام سلمان

ملخص

في ظل التغيرات المناخية المتسارعة والحاجة المتزايدة إلى أنظمة دقيقة لتوقع الأحوال الجوية، يأتي هذا المشروع كمساهمة عملية في تطوير تطبيق ويب يستخدم تقنيات الذكاء الاصطناعي لتوقع حالة الطقس، تم بناء النظام باستخدام إطار عمل Streamlit بلغة Python، ويعتمد على خوارزمية الانحدار الخطي (Linear Regression) لتوقع القيم المستقبلية لمتغيرات الطقس مثل درجة الحرارة، والرطوبة، وسرعة الرياح.

يعتمد التطبيق على بيانات أرشيفية يتم جلبها من واجهة API خاصة بموقع Open-Meteo، ثم يتم معالجتها وتنظيفها باستخدام تقنيات تعلم الآلة، وتدريب النموذج على مدى زمني مدته سنتان لتوقع حالة الطقس لكل ساعة من ساعات اليوم التالي بدقة عالية.

يتميز النظام بواجهة تفاعلية سهلة الاستخدام تسمح للمستخدم باختيار الدولة والمدينة وواحدة البارامترات المرغوبة لعرض البيانات لها، وكذلك اختيار نوع المتغيرات التي يرغب بتوقعها، كما يتيح عرض النتائج بشكل بياني ومخططات وجداول إحصائية تسهل الفهم والاستفادة.

يمثل هذا المشروع مثلاً واقعياً على تكامل الذكاء الاصطناعي مع تقنيات الويب وتطبيقاته العملية في خدمة الحياة اليومية، ويشكل خطوة نحو تطوير أنظمة تنبؤ طقس أكثر ذكاء وتفاعلية في المستقبل. تم تنفيذ المشروع على منصة Google Colab، ويمكن الاطلاع على الوثائق التجريبية على الرابط التالي: [Google Colab](#).

تم بناء واجهة المستخدم باستخدام مكتبة Streamlit، ويمكن للمستخدمين التفاعل مع التطبيق مباشرة عبر الرابط: [Streamlit](#).

تم تخزين الكود والمستندات الخاصة بالمشروع على GitHub، ويمكن الوصول إليها عبر الرابط: [GitHub](#).

الفهرس

رقم الفقرة	عنوان الفقرة	الصفحة
-1	المقدمة	1
-2	هدف المشروع وأهميته	2
-3	التحديات والقضايا	3
-4	أبحاث ودراسات سابقة	4
-5	الذكاء الاصطناعي (AI)	8
-6	انترنت الأشياء (IOT)	10
-7	طريقة العمل والأدوات المستخدمة	10
-8	المشاكل التي واجهت الباحث	15
-1-8	محاولة استخدام الشبكات العصبونية العميقة	15
-9	المشكلة العلمية ومبررات مشروع البحث	16
-10	الاستنتاجات والتوصيات	17
أولاً:	الاستنتاجات	17
ثانياً:	التوصيات	18
-11	المراجعة المستخدمة في مجال البحث	20

جدول المصطلحات

المصطلح	الوصف العربي	الوصف الانكليزي
AI	الذكاء الاصطناعي	Artificial Intelligence
ML	تعلم الآلة	Machine Learning
API	واجهة برمجة التطبيقات	Application Programming Interface
Dataset	مجموعة البيانات	Dataset
IOT	انترنت الاشياء	Internet Of Things
CSV	ملف القيم المفصولة بفواصل	Comma-separated Values
Streamlit	إطار عمل لتطوير تطبيقات الويب التفاعلية بلغة بايثون	Streamlit Framework
Linear Regression	الانحدار الخطي	Linear Regression
Prediction	التنبؤ	Prediction
MAE	متوسط الخطأ المطلق	Mean Absolute Error
DNN	الشبكة العصبية العميقة	Deep Neural Network
ARIMA	نموذج الانحدار الذاتي المتوسط المتحرك المتكامل	AutoRegressive Integrated Moving Average

جداول الأشكال

الصفحة	اسم الشكل	رقم الشكل
9	تشابك وترابط فروع الذكاء الاصطناعي	الشكل (1)
11	أعدادات الـ look_back لأجل 24 ساعة	الشكل (2)
11	أعدادات الـ look_back لأجل 48 ساعة	الشكل (3)
12	أعدادات الـ look_back لأجل 72 ساعة	الشكل (4)
13	واجهة تطبيق التنبؤ بالطقس	الشكل (5)

1- المقدمة

يُعدّ الطقس من أكثر العوامل تأثيراً في حياة الإنسان اليومية، فهو يتحكم في أنشطته، وسفره، وصحته، وحتى اقتصاد الدول. ومع تطور العلوم والتكنولوجيا، أصبح بالإمكان التنبؤ بالطقس بدقة جيدة لفترات قصيرة، إلا أن هذا التنبؤ لا يزال يواجه تحديات متعددة تتعلق بالدقة والسرعة والموثوقية، خاصة في ظل التغيرات المناخية المتسارعة التي يشهدها العالم.

خلال السنوات الأخيرة، برز الذكاء الاصطناعي ك تقنية واحدة في مجالات متعددة، من أبرزها تحليل البيانات واستخراج الأنماط منها، وهو ما جعله أداة مثالية لتحسين دقة التنبؤات الجوية، إذ يمكن لتقنيات تعلم الآلة، من خلال تدريب النماذج على كميات ضخمة من البيانات المناخية التاريخية، أن تتعلم العلاقة بين المتغيرات الجوية المختلفة، مثل درجة الحرارة والرطوبة وسرعة الرياح، وأن تتنبأ بسلوكها المستقبلي.

في هذا السياق، يأتي هذا المشروع لتقديم نموذج تطبيقي عملي يستخدم الذكاء الاصطناعي عبر خوارزمية الانحدار الخطي (Linear Regression) لبناء نظام ذكي قادر على التنبؤ بالطقس لكل ساعة في اليوم التالي، بناءً على بيانات أرشيفية يتم الحصول عليها من واجهة برمجة تطبيقات (API) متخصصة، حيث تم تصميم التطبيق بواجهة تفاعلية باستخدام Streamlit، تتيح للمستخدم اختيار المدينة والوحدة المناسبة وتحليل النتائج بطريقة مرئية وسهلة الفهم.

هذا المشروع لا يقدم فقط حلاً تقنياً لمشكلة آنية، بل يشكل أيضاً مثالاً على كيفية دمج الذكاء الاصطناعي مع تطبيقات الويب الحديثة في بناء أنظمة فعالة وذات فائدة مباشرة للمستخدمين.

2- هدف المشروع وأهميته

تقوم فكرة هذه الدراسة على تصميم وتنفيذ نظام ذكي للتنبؤ بالطقس بالاعتماد على تقنيات الذكاء الاصطناعي، بهدف تحسين دقة التنبؤات الجوية وتقليل الاعتماد على النماذج التقليدية المعقدة، حيث يركز المشروع على تقديم حل عملي مبني على خوارزميات تعلم الآلة، يتيح للمستخدم التنبؤ بالقيم المستقبلية لمتغيرات مناخية رئيسية مثل: درجة الحرارة، الرطوبة، وسرعة الرياح.

تتبع أهمية المشروع من الحاجة المتزايدة إلى حلول تنبؤية دقيقة، قابلة للتطبيق بسهولة من قبل المستخدم العادي أو الجهات المختصة، مع مراعاة تنوع احتياجاتهم من حيث الموقع الجغرافي، والوحدات المستخدمة، ونوع البيانات المناخية المطلوبة، ومن هذا المنطلق تم الاعتماد على خوارزمية الانحدار الخطي Linear Regression كنموذج أولي لتوليد تنبؤات تعتمد على بيانات أرشيفية تاريخية يتم الحصول عليها من واجهة برمجة تطبيقات متخصصة.

تتمثل الركائز الأساسية لأهداف المشروع في ما يلي:

1. بناء نموذج تنبؤي باستخدام الذكاء الاصطناعي يمكن تدريبه تلقائياً على بيانات الطقس التاريخية لأي مدينة في العالم.
2. السماح للمستخدم باختيار الدولة والمدينة والمتغيرات المناخية المراد التنبؤ بها، مع اختيار وحدة القياس المناسبة.
3. توفير نتائج التنبؤ بشكل مرئي من خلال رسوم بيانية وجداول لكل ساعة من اليوم التالي، مما يساعد المستخدم في اتخاذ قرارات مبنية على معلومات دقيقة.
4. تقديم واجهة استخدام تفاعلية وسهلة مبنية على مكتبة Streamlit، تدعم اللغتين العربية والإنجليزية، وتراعي مرونة العرض وسهولة الاستخدام.

إن هذا المشروع لا يهدف فقط إلى تطبيق تقنيات الذكاء الاصطناعي في التنبؤ المناخي، بل يسعى أيضاً إلى تبسيط الوصول إلى هذه التقنيات، وجعلها في متناول المستخدمين من خلال بيئة تفاعلية توضح نتائج النماذج بشكل عملي وسهل الفهم.

3- التحديات والقضايا

يشكل التنبؤ بالطقس تحدياً علمياً وتقنياً واسع النطاق، نظراً لطبيعة البيانات المناخية المعقدة، وتداخل العوامل المؤثرة في الظواهر الجوية، ويزداد هذا التحدي مع تزايد الحاجة إلى دقة أعلى وسرعة أكبر في التنبؤ، خصوصاً مع التغيرات المناخية الحادة التي تشهدها الكرة الأرضية في العقود الأخيرة. من أبرز التحديات التي يواجهها التنبؤ في هذا المجال:

الحجم الهائل للبيانات المناخية: تعتمد أنظمة التنبؤ الحديثة على بيانات يتم جمعها من الأقمار الاصطناعية، والمرصد الأرضية، والمجسات، مما يولد كميات ضخمة من المعلومات التي تتطلب خوارزميات فعالة لتحليلها.

البيانات المفقودة والضوضاء: كثيراً ما تحتوي السجلات المناخية على بيانات مفقودة أو غير دقيقة، وهو ما قد ينعكس سلباً على جودة التنبؤ، لذا تبرز الحاجة إلى أدوات ذكية لمعالجة هذه البيانات وتعبئة الفجوات.

صعوبة النمذجة التقليدية: تعتمد النماذج الفيزيائية التقليدية على معادلات تفاضلية معقدة تتطلب قدرات حسابية هائلة، ولا تستطيع في بعض الأحيان التقاط الأنماط غير الخطية أو العشوائية في السلوك المناخي.

التفاعل مع المستخدم: يتطلب تقديم نتائج التنبؤ بطريقة مرئية وسهلة الفهم، مع السماح للمستخدم بالتحكم في اختيار المدينة، والمتغيرات المناخية، ووحدات القياس المناسبة له.

التنقل بين اللغات والثقافات: يفرض اختلاف المستخدمين تحدياً إضافياً، حيث يجب تصميم النظام بطريقة تدعم تعدد اللغات، خاصة عند استخدامه في بيئات تعليمية أو مجتمعية متنوعة. كل هذه التحديات تستدعي حلولاً مبتكرة، تجمع بين بساطة الاستخدام ودقة الأداء، وقد تم في هذا المشروع تجاوز كثير من هذه القضايا من خلال الاعتماد على الذكاء الاصطناعي، وتحديدًا خوارزمية الانحدار الخطي، إلى جانب تطوير واجهة استخدام تفاعلية تعتمد على مكتبة Streamlit، تتيح التخصيص الكامل للخيارات بطريقة مرنة وسريعة.

4- أبحاث ودراسات سابقة

شهد مجال التنبؤ بالطقس باستخدام تقنيات الذكاء الاصطناعي وتعلم الآلة تطوراً ملحوظاً خلال السنوات الأخيرة، حيث تم تطوير العديد من النماذج التي تتجاوز النماذج التقليدية المعتمدة على المعادلات الفيزيائية.

1. التنبؤ بالطقس الاحتمالي باستخدام التعلم الآلي

تركز هذه الدراسة على تحسين التنبؤات الجوية من خلال تقديم نموذج GenCast وهو نموذج احتمالي يعتمد على التعلم الآلي للتنبؤ بالطقس على عكس التنبؤات التقليدية القائمة على النماذج العددية للتنبؤ بالطقس (NWP)، والتي غالباً ما تكون محددة ولا تعكس عدم اليقين، حيث يقوم GenCast بإنتاج مجموعة من التنبؤات العشوائية لمدة 15 يوماً بدقة عالية، وبخطوات زمنية كل 12 ساعة وبدقة مكانية 0.25° خطوط العرض والطول لأكثر من 80 متغيراً جويًا وسطحياً.

تم تدريب النموذج على بيانات إعادة التحليل لعقود من الزمن، وأظهر نتائج تفوق التنبؤات التشغيلية الأوروبية ENS في 97.2% من الحالات التي تم تقييمها، بما في ذلك التنبؤ بالأحداث الجوية

القصى، مسارات الأعاصير المدارية، وإنتاج الطاقة من الرياح، حيث تقدم الدراسة نموذجاً أسرع وأكثر دقة للتنبؤات الجوية، مما يسهم في دعم القرارات الحيوية المعتمدة على الطقس بشكل أكثر فعالية.

رابط الدراسة:

<https://www.nature.com/articles/s41586-024-08252-9>

2. أساليب التعلم الآلي للتنبؤ بالطقس: دراسة استقصائية

ركز مجموعة من الباحثين على التنبؤ بالطقس باستخدام تقنيات تعلم الآلة، حيث أثبتت هذه الأساليب قدرتها على معالجة البيانات المعقدة وذات الأبعاد العالية والاستفادة من كميات كبيرة من البيانات التاريخية والفورية. تبحث الدراسة في تطبيقات متعددة مثل التنبؤ العالمي بالطقس، التنبؤ المناخي (downscaling)، التنبؤ بالظواهر الجوية القصوى، ودمج أساليب تعلم الآلة مع المبادئ الفيزيائية. ورغم التقدم الكبير لا تزال هناك تحديات قائمة مثل صعوبة تفسير نماذج تعلم الآلة والتنبؤ بالأحداث النادرة.

تشير الدراسة إلى أن معالجة هذه القضايا ستسهم في تعزيز دقة التنبؤات الجوية وتكاملها مع النماذج التقليدية.

رابط الدراسة:

<https://www.mdpi.com/2073-4433/16/1/82>

3. التنبؤ بدرجات الحرارة القائم على التعلم الآلي للتكيف والتخفيف المستدام من تغير المناخ

في هذه الدراسة تم استخدام الشبكات العصبية الاصطناعية (ANN) ونماذج التعلم الآلي (النموذج الخطي، آلة المتجهات الداعمة، الجار الأقرب، الغابات العشوائية) لتقدير درجة الحرارة ودعم التخطيط البيئي المستدام وتطوير حلول التكيف مع التغير المناخي.

تم تحليل بيانات الرطوبة الشهرية وسرعة الرياح والهطول ودرجة الحرارة لمقاطعة إسطنبول خلال الفترة 1950-2023، حيث أظهرت نتائج الدراسة أن نموذج ANN حقق دقة تصل إلى 96%، بينما كان

أداء نموذج الغابات العشوائية الأعلى بين نماذج التعلم الآلي الأخرى.

تم تعزيز قدرة تعميم النماذج باستخدام طريقة k-fold cross-validation.

أظهرت التحليلات وجود ارتباط سلبي بين المتغيرات المدخلة (الرطوبة، الرياح، الهطول) ودرجة الحرارة، وتشير النتائج إلى أن تقنيات الذكاء الاصطناعي والتعلم الآلي تمثل أدوات فعالة لمراقبة المناخ المستدام وتقدير درجات الحرارة، ويمكن تطبيق المنهجية على تحليلات مناخية إقليمية أخرى لدعم اتخاذ القرارات المبنية على الأدلة من أجل التنمية المستدامة والقدرة على التكيف مع التغير المناخي.

رابط الدراسة:

<https://www.mdpi.com/2071-1050/17/5/1812>

4. التحقق من صحة نماذج التنبؤ بالطقس القائمة على التعلم العميق في الأحداث المتطرفة عالية

التأثير الأخيرة

تشير هذه الدراسة إلى التقدم السريع في دقة نماذج التنبؤ بالطقس المعتمدة على التعلم الآلي (ML)، ما يوصف أحياناً بـ "الثورة الثانية في التنبؤ بالطقس"، ومع ذلك تواجه هذه النماذج تحديات تتعلق بتقييم الأحداث النادرة والمتطرفة وتأثيراتها المركبة، حيث قد تتخفف الدقة بسبب تمثيل العلاقات بين المتغيرات بشكل غير دقيق، ولمواجهة ذلك قامت الدراسة بمقارنة نماذج ML مثل GraphCast و Pangu-Weather و FourCastNet مع نظام التنبؤ عالي الدقة التابع لـ ECMWF (HRES) من خلال ثلاث دراسات حالة: موجة الحر في شمال غرب المحيط الهادئ 2021، موجة الحر الرطبة في جنوب آسيا 2023، وعاصفة الشتاء في أمريكا الشمالية 2021.

أظهرت النتائج أن نماذج ML تصل دقتها محلياً إلى مستويات HRES في موجة الحر القياسية، لكنها أقل دقة عند تجميع البيانات عبر الزمان والمكان، وبالمقابل تفوقت نماذج ML في التنبؤ بالعاصفة الشتوية المركبة، كما أبرزت الدراسة الاختلافات الهيكلية في تراكم الأخطاء بين HRES ونماذج ML، وأكدت أن النماذج القائمة على ML تنقصر إلى بعض المتغيرات الأساسية لتقييم المخاطر الصحية بدقة خلال موجة الحر الرطبة في 2023، حيث تم تقدير مناطق الخطر الأعلى في بنغلاديش بأقل من الواقع، حيث تشير الدراسة إلى أن التقييم المعتمد على دراسات الحالة والمخاطر يمكن أن يكمل الأبحاث الحالية ويزيد الثقة العامة ويساعد في تطوير نماذج ML أكثر موثوقية للتنبؤ بالطقس.

رابط الدراسة:

<https://journals.ametsoc.org/view/journals/aies/4/1/AIES-D-24-0033.1.xml>

5. التنبؤ بالطقس القائم على البيانات الشاملة

تستعرض هذه الدراسة نظام Aardvark Weather، وهو نموذج تنبؤ بالطقس معتمد بالكامل على التعلم الآلي قادر على استبدال كامل سلسلة التنبؤ العددية التقليدية (NWP)، ويقوم النظام بمعالجة البيانات المرصودة لإنتاج تنبؤات عالمية ومحلية دقيقة، متفوقاً على الأنظمة التشغيلية التقليدية في عدة متغيرات وفترات زمنية، كما تظهر النتائج أن التنبؤ المحلي دقيق حتى عشرة أيام مسبقاً، ويقارن بشكل تنافسي مع أفضل أنظمة التنبؤ الحالية، حيث يوضح البحث أن التنبؤ الدقيق ممكن دون الاعتماد على (NWP) عند التنفيذ، مما يتيح تحسين سرعة وكفاءة النماذج وتقليل التكاليف الحسابية بشكل كبير، وفتح الطريق لإنشاء نماذج مخصصة بسرعة للمستخدمين المختلفين.

رابط الدراسة:

<https://www.nature.com/articles/s41586-025-08897-0>

6. حول بعض القيود المفروضة على نماذج التنبؤ بالطقس الحالية القائمة على التعلم الآلي

تستعرض هذه الدراسة أداء ثلاثة نماذج حديثة للتنبؤ بالطقس باستخدام التعلم الآلي (Pangu-Weather و FourCastNet و GraphCast) مع التركيز على دقتها والتوافق الفيزيائي لتنبؤاتها، حيث وجدت الدراسة أن هذه النماذج غير قادرة على تمثيل الظواهر الجوية تحت المقياس الكبير والمتوسط بشكل صحيح وتفتقر إلى الدقة والتوافق الفيزيائي مقارنة بالنماذج التقليدية المعتمدة على الفيزياء.

يشير ذلك إلى أن تحقيق توازن بين مهارة التنبؤ والواقعية الفيزيائية سيكون أمراً أساسياً لتطوير النماذج المستقبلية للتعلم الآلي.

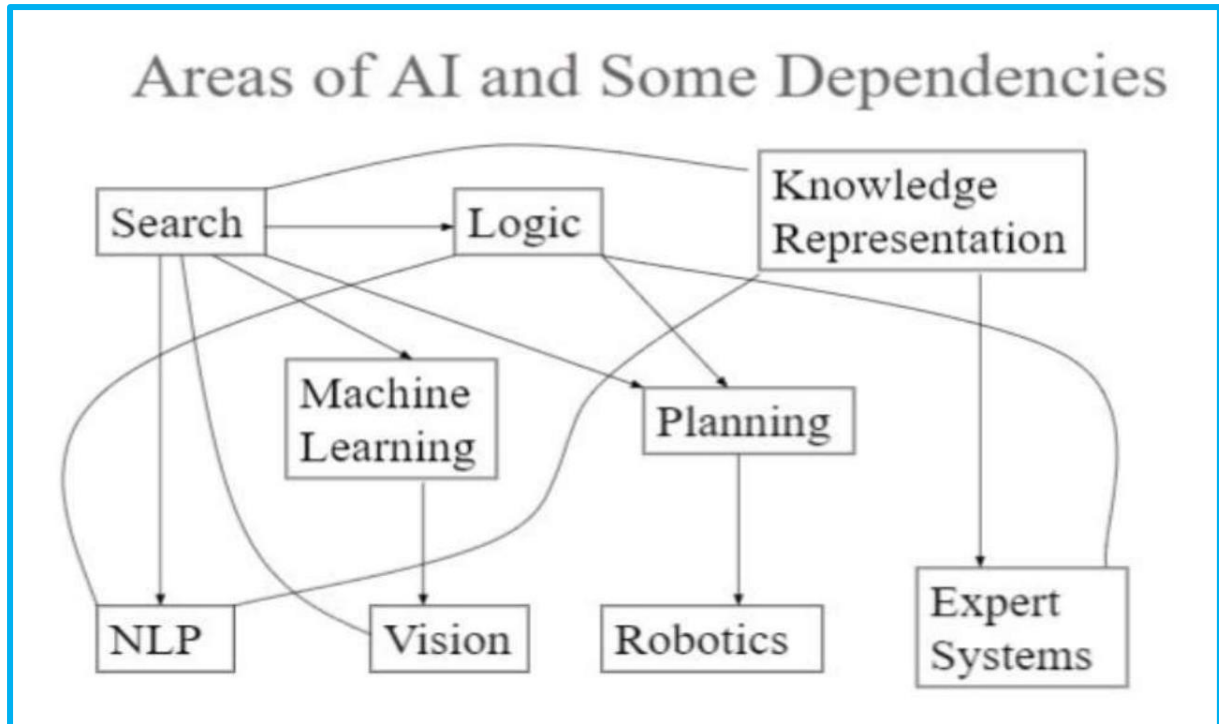
رابط الدراسة:

<https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2023GL107377>

5- الذكاء الاصطناعي (AI)

أصبح الذكاء الاصطناعي في عصرنا هذا حقيقة ملموسة بعد أن كان خيالاً علمياً نشاهده في أفلام السينما وأصبحت تطبيقات الذكاء الاصطناعي تحيط بنا وأصبح الناس يرون تأثيرها في دور السينما وعلى أجهزتهم الذكية وعلى الانترنت بالأخص.

الاختصاصيون في هذا المجال يعرفون مدى التشعبات والفروع التي تتطوي تحت هذا العنوان العريض والعريض جداً، سابقاً كان يُفهم من الذكاء الاصطناعي موضوعات تنحصر بالتعرف على الصورة والتعرف على الوجوه والتوزيع الأمثل، لكن الذكاء الاصطناعي يحتوي عدة مجالات ولكل مجال منها علم قائم بحد ذاته وهذه الفروع متشابكة ومتراصة كما هو موضح بالشكل (1)



الشكل (1): تشابك وترابط فروع الذكاء الاصطناعي.

هنالك مجالات للذكاء الاصطناعي وهي على سبيل الذكر لا الحصر:

البحث Search.

والشبكات العصبونية NN.

الروبوتيك Robotics.

والنظم الخبيرة ES.

والمنطق Logic.

وتعلم الآلة Machine Learning.

والتخطيط Planning.

وتمثيل المعرفة Knowledge Representation.

وفروع عديدة اخرى يمكن أن تندرج تحت أحد التقسيمات أو الفروع أو المجالات السابقة كالتعلم

العميق Deep Learning و الخوارزميات الجينية Genetic Algorithms.

6- إنترنت الأشياء (IOT) Internet Of Things

هو الاحاطة ب شيء مرتبط بالانترنت وبارتباط الشبكات الاخرى إلى حساسات مختلفة قادرة على جمع وإرسال البيانات إلى شبكات لاسلكية دون تدخل الانسان.

الحساسات المرتبطة بمقاييس أجهزة قياس درجة الحرارة الذكية مصممة بميزة قياس لتلك الحرارة

والتي تستطيع كشف عن درجة الحرارة اللحظية والتبليغ عن القياس إلى منصة IOT

بواسطة هذه التقنية نستطيع توسيع قاعدة المعطيات للقياسات (قيمتها ,موقعها ..) بالإضافة إلى

المعلومات الواردة من مراكز الرصد الجوي، حيث يستخدم معلومات مراكز الرصد الجوي ومعطيات

شبكة حساسات IOT ويعالجها وبواسطة تقنيات الذكاء الاصطناعي يضع تنبؤ لدرجة الحرارة ويعرض

النتائج على الهواتف الذكية والشاشات الذكية والأشياء الاخرى المرتبطة بالإنترنت.

7- طريقة العمل والأدوات المستخدمة

في المرحلة الأولى من المشروع، تم العمل على منصة Google Colab لبناء نماذج تعلم آلي مختلفة

واختبارها على بيانات الطقس من أجل التنبؤ بدرجات الحرارة، ويمكن الاطلاع على الوثائق التجريبية

على الرابط التالي: [Google Colab](https://colab.research.google.com/).

تم القيام بتجريب ومقارنة أربع نماذج مختلفة وهي:

Linear Regression

Random Forest

Support Vector Regression (SVR)

XGBoost

تمت المقارنة بين هذه النماذج بناءً على معيارين أساسيين:

متوسط الخطأ المطلق (MAE).

زمن التدريب والتنبؤ (Time in seconds).

حيث تمت التجربة باستخدام ثلاث إعدادات مختلفة لقيمة look_back وهي:

(24 - 48 - 72 ساعة ماضية).

وأظهرت التجارب أن استخدام 72 ساعة ماضية أعطى أفضل دقة (بأقل MAE) مع الحفاظ على زمن

تدريب معقول، كما هو موضح في الأشكال (2,3,4) المرفقة بالنتائج بالإضافة إلى رابط Google

Colab للتوثيق الكامل للخطوات والمقارنات، والتي تظهر النتائج المقارنة لكل حالة من الحالات

السابقة.

```
Linear Regression MAE: 0.61 | Time: 0.05 seconds
Random Forest MAE: 0.64 | Time: 21.91 seconds
SVR MAE: 0.66 | Time: 13.94 seconds
XGBoost MAE: 0.64 | Time: 0.24 seconds
```

Model Comparison Results:

	MAE	Time (s)
Linear Regression	0.614182	0.054317
Random Forest	0.638505	21.905101
SVR	0.655902	13.942120
XGBoost	0.643123	0.242130

الشكل (2): أعدادات الـ look_back لأجل 24 ساعة.

```
Linear Regression MAE: 0.58 | Time: 0.02 seconds
Random Forest MAE: 0.64 | Time: 34.23 seconds
SVR MAE: 0.70 | Time: 15.37 seconds
XGBoost MAE: 0.63 | Time: 0.41 seconds
```

Model Comparison Results:

	MAE	Time (s)
Linear Regression	0.583325	0.023515
Random Forest	0.643574	34.227875
SVR	0.698887	15.374502
XGBoost	0.632967	0.413208

الشكل (3): أعدادات الـ look_back لأجل 48 ساعة.


```
Linear Regression MAE: 0.58 | Time: 0.05 seconds
Random Forest MAE: 0.64 | Time: 55.31 seconds
SVR MAE: 0.76 | Time: 18.68 seconds
XGBoost MAE: 0.63 | Time: 1.82 seconds
```

Model Comparison Results:

	MAE	Time (s)
Linear Regression	0.577610	0.051926
Random Forest	0.642961	55.310519
SVR	0.762697	18.678120
XGBoost	0.632539	1.819949

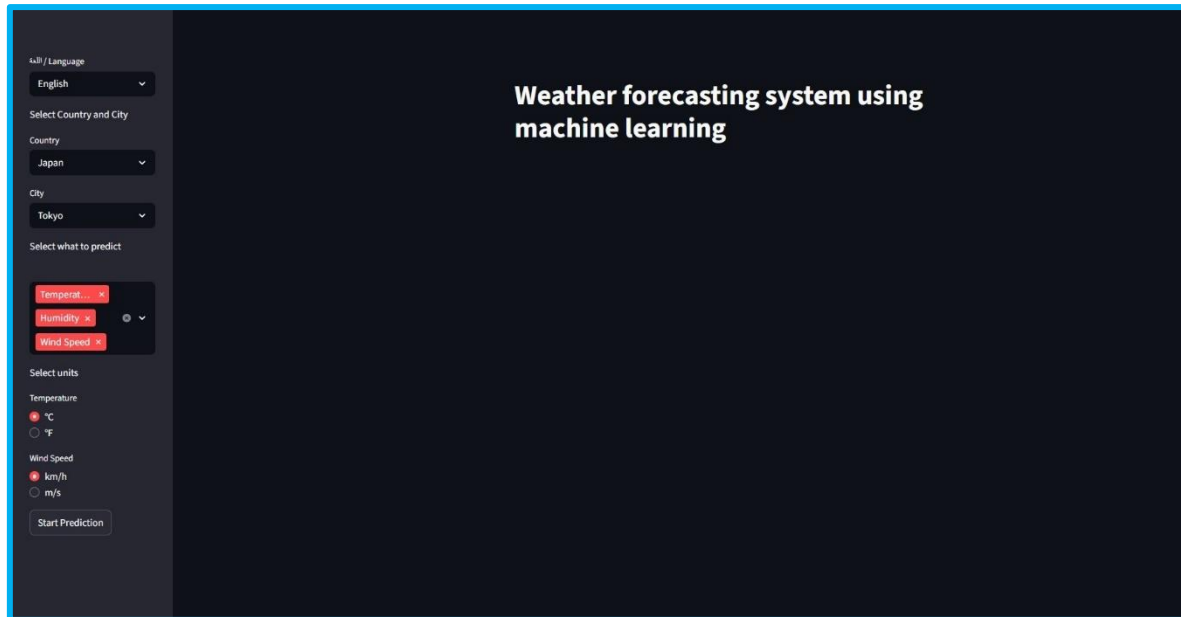
الشكل (4): أعدادات الـ look_back لأجل 72 ساعة.

بعد أن تم اختيار الإعدادات الأنسب وهو $look_back = 72$ ، والنموذج الأفضل من ناحية التوازن بين

الدقة والسرعة وهو Linear Regression، قمنا بالانتقال إلى GitHub، ويمكن الوصول إليها عبر

الرابط [GitHub](#) والبدء ببناء التطبيق النهائي باستخدام الأدوات الآتية:

- لغة البرمجة Python.
 - مكتبة Streamlit لإنشاء واجهة المستخدم.
 - مكتبة scikit-learn لبناء وتدريب النموذج.
 - مكتبة Matplotlib للرسم البياني.
 - مكتبة pandas و numpy لمعالجة البيانات.
- تم ربط المشروع مع منصة Streamlit Cloud لعرض التطبيق على الإنترنت بشكل مباشر.
- حيث يمثل الشكل (5) واجهة التطبيق.



الشكل (5): واجهة تطبيق التنبؤ بالطقس

يعتمد المشروع على تطوير تطبيق ويب تفاعلي لتوقع الطقس باستخدام خوارزميات تعلم الآلة، مع الاستفادة من بيانات أرشيفية حقيقية تغطي آخر سنتين من السجلات الجوية، تم تنفيذ المشروع باستخدام لغة البرمجة Python ومكتبة Streamlit لبناء واجهة المستخدم، بالإضافة إلى مكتبات تحليل البيانات وتعلم الآلة، ويمكن للمستخدمين التفاعل مع التطبيق مباشرة عبر الرابط: [Streamlit](#).

خطوات العمل:

1. جمع البيانات:

- تم استخدام واجهة برمجية (API) من موقع open-meteo.com للحصول على بيانات تاريخية لحالة الطقس تشمل: درجة الحرارة، نسبة الرطوبة، وسرعة الرياح لكل ساعة ولمدة سنتين.

2. معالجة البيانات:

- تم تحويل البيانات إلى إطار بيانات باستخدام pandas.

○ معالجة القيم المفقودة عبر تقنيتين:

- في حال وجود فراغ بين قيمتين معلومتين، يتم إدراج المتوسط الحسابي لهما.
- استخدام التعبئة الأمامية (ffill) والخلفية (bfill) لتغطية باقي الفراغات.

3. تحضير البيانات للنموذج:

- تم استخدام نافذة زمنية ($look_back = 72$) أي أن النموذج يتعلم من القيم السابقة لثلاثة أيام (72 ساعة) ليقوم بتوقع الساعات القادمة.
- تم تقسيم البيانات إلى بيانات تدريب بنسبة 80% وبيانات اختبار بنسبة 20%.

4. اختيار النموذج:

- تم استخدام خوارزمية الانحدار الخطي (Linear Regression) كخوارزمية تنبؤ أساسية نظراً لبساطتها وسرعتها وفعاليتها مع هذا النوع من البيانات.

5. التنبؤ:

- يتم التنبؤ بدرجات الحرارة والرطوبة وسرعة الرياح لكل ساعة لليوم التالي (24 ساعة قادمة).

6. عرض النتائج:

- يتم عرض النتائج للمستخدم من خلال رسوم بيانية لكل متغير مختار.
- يمكن للمستخدم اختيار الدولة والمدينة والوحدات المفضلة لكل من درجة الحرارة وسرعة الرياح.

الأدوات والتقنيات المستخدمة:

- Python لغة البرمجة الأساسية.
- Streamlit لبناء واجهة المستخدم التفاعلية.
- Pandas لمعالجة وتحليل البيانات.
- NumPy للعمليات الرياضية.

- Matplotlib لعرض الرسوم البيانية.
- Scikit-learn لتطبيق خوارزميات تعلم الآلة (Linear Regression).
- Open-Meteo API للحصول على بيانات الطقس التاريخية.
- CSV Dataset (worldcities.csv) لتحديد مواقع الدول والمدن مع الإحداثيات الجغرافية.

8- المشاكل التي واجهت الباحث

8-1- محاولة استخدام التعلم العميق (Deep Learning):

خلال مراحل تطوير المشروع، تم التفكير في استخدام نماذج تعتمد على التعلم العميق (Deep Learning)، مثل الشبكات العصبونية LSTM، والتي تُعد مناسبة جداً للتعامل مع البيانات الزمنية كدرجات الحرارة والرطوبة وسرعة الرياح.

رغم أن تقنيات التعلم العميق تعتبر متقدمة وقوية، خصوصاً في التعامل مع البيانات الزمنية، فقد تم العدول عن استخدامها في هذا المشروع للأسباب التالية:

1. قيود الموارد الحسابية في Google Colab:

عند تجربة هذه النماذج على Google Colab، واجهت صعوبات متعلقة بمحدودية الموارد المتوفرة، مثل الذاكرة (RAM) وسرعة قراءة وكتابة وتخزين البيانات (Disk)، خاصة عند التعامل مع بيانات ضخمة تمتد لسنتين بواقع قراءات كل ساعة.

2. طول وقت التدريب:

يتطلب التدريب الكامل لهذه النماذج وقتاً طويلاً نسبياً مقارنة بالنماذج التقليدية، مما يتعارض مع هدف المشروع في توفير تجربة تفاعلية سريعة على واجهة Streamlit.

3. الأداء الجيد للنماذج التقليدية:

عند تجربة نماذج مثل Linear Regression وXGBoost، تم الوصول إلى أداء جيد وخطأ MAE منخفض مع سرعة تدريب عالية، مما جعل استخدام النماذج العميقة غير ضروري في هذه المرحلة.

ونتيجة لذلك، تم الاكتفاء باستخدام نماذج تقليدية فعالة Linear Regression والتي قدّمت دقة جيدة وسرعة في التنفيذ مقارنة بقدرات النظام المتاحة.

9- المشكلة العلمية ومبررات مشروع البحث

تعد توقعات الطقس من العناصر الحيوية في حياة الأفراد والمجتمعات، حيث تؤثر بشكل مباشر على القطاعات الزراعية، والاقتصادية، والنقل، والطاقة، وحتى على السلامة العامة، ومع أن خدمات التنبؤ التقليدية أصبحت متوفرة، إلا أنها لا تقدم غالباً توقعات دقيقة على المدى القريب (قصير الأجل على مستوى الساعات)، خاصة عندما يتعلق الأمر بتوقع درجات الحرارة أو الرطوبة أو سرعة الرياح في مدينة محددة.

من الناحية العلمية فإن نماذج الأرصاد الجوية التقليدية تعتمد على معادلات فيزيائية معقدة، وتتطلب قدرات حوسبة هائلة، بالإضافة إلى ذلك، تكون مخرجاتها أحياناً غير دقيقة بسبب حساسية النظام الجوي لأي تغير طفيف في البيانات الأولية.

يهدف هذا المشروع إلى توظيف تقنيات الذكاء الاصطناعي، وتحديد خوارزميات التعلم الآلي، لبناء نموذج قادر على التنبؤ الفعال بالطقس لمدة 24 ساعة قادمة، بالاعتماد على بيانات أرشيفية تم جمعها من API مفتوح المصدر، حيث تمت معالجة هذه البيانات وتدريب النموذج باستخدام خوارزمية

الانحدار الخطي (Linear Regression) ضمن بيئة تطوير تفاعلية باستخدام Python وواجهة Streamlit.

تبرز أهمية هذا المشروع من خلال:

1. تحقيق تنبؤ فوري وتفاعلي للمستخدم النهائي دون الحاجة لانتظار نتائج من خوادم خارجية.
2. إتاحة التنبؤ لأي مدينة في العالم من خلال دمج ملف يحتوي على إحداثيات آلاف المدن العالمية.
3. سهولة الاستخدام والبساطة، إذ يمكن لأي شخص غير مختص استخدام التطبيق والتفاعل مع نتائجه.

4. دعم لغتين (العربية والإنجليزية) مما يعزز الوصول إلى شرائح أوسع من المستخدمين.
5. تحقيق نتائج جيدة باستخدام نماذج بسيطة، ما يثبت فعالية النهج المستخدم ويدعم توسيعه في المستقبل.

لذلك، فإن هذه الدراسة تشكل خطوة عملية نحو بناء أدوات ذكية تساعد المستخدم على اتخاذ قرارات أفضل بناءً على توقعات دقيقة، باستخدام تقنيات مفتوحة المصدر وبيئات تطوير مرنة.

10- الاستنتاجات والتوصيات

أولاً: الاستنتاجات

من خلال تنفيذ هذا المشروع وتحليل نتائجه، يمكن استخلاص الاستنتاجات التالية:

1. فعالية النماذج البسيطة
- أظهر نموذج الانحدار الخطي (Linear Regression) أداءً جيداً في التنبؤ بالطقس لمدة 24 ساعة قادمة، وذلك عند استخدام بيانات أرشيفية واسعة تمتد لسنتين، مما يعكس قدرة النماذج التقليدية على التعامل مع الأنماط الزمنية في بيانات الطقس متى ما تم إعدادها ومعالجتها بشكل جيد.

2. دور حجم بيانات الإدخال (Look Back)

تمت تجربة عدة قيم لـ Look Back (24، 48، 72 ساعة)، وتبين أن استخدام 72 ساعة كمداخلات للتنبؤ أعطى أفضل نتائج من حيث دقة التنبؤ (MAE)، مما يؤكد أن زيادة السياق الزمني للنموذج تُحسن التوقعات.

3. أهمية المعالجة المسبقة للبيانات

لعبت معالجة القيم المفقودة دوراً جوهرياً في تحسين أداء النموذج، إذ تم استخدام تقنيات مثل المتوسط بين القيمتين المجاورتين والتعبئة الأمامية والخلفية (ffill/bfill)، مما ساهم في تقليل الأخطاء وتحقيق استقرار في النموذج.

4. سهولة الوصول عبر الويب

وفر استخدام Streamlit و GitHub منصة تفاعلية وسهلة الاستخدام لعرض النموذج للمستخدم النهائي، دون الحاجة إلى تثبيت أي برنامج أو وجود خبرة تقنية.

ثانياً: التوصيات

استناداً إلى ما سبق، يمكن تقديم التوصيات التالية لتطوير المشروع أو الاستفادة منه في مشاريع مشابهة:

1. توسيع استخدام النماذج

يُنصح مستقبلاً بتجريب نماذج أكثر تعقيداً مثل الشبكات العصبونية LSTM، والتي أثبتت كفاءتها في التعامل مع البيانات الزمنية، مع الأخذ بعين الاعتبار الحاجة إلى موارد حوسبية أعلى.

2. دعم المزيد من المتغيرات المناخية

يمكن مستقبلاً إضافة متغيرات مثل الضغط الجوي، الغطاء السحابي، أو احتمال الهطول لزيادة شمولية التوقع.

3. إتاحة التنبؤ لفترات أطول

حالياً، النموذج يتنبأ لـ 24 ساعة فقط. يمكن في النسخ القادمة زيادة المدى الزمني إلى 48 أو 72 ساعة مع الحفاظ على دقة مناسبة.

4. دمج تنبيهات ذكية

كميزة مستقبلية، يمكن تنبيه المستخدم بدرجات حرارة حرجة أو رياح قوية بناءً على التنبؤات القادمة، مما يزيد من القيمة العملية للتطبيق.

5. تحسين الواجهة وتجربة المستخدم

من خلال إضافة رسوم بيانية أكثر تفاعلية، أو دعم تطبيقات الهاتف المحمول، ليصبح النموذج أداة فعلية قابلة للاستخدام اليومي.

References

- 1- Price, I., Sanchez-Gonzalez, A., Alet, F., Andersson, T. R., El-Kadi, A., Masters, D., Ewalds, T., Stott, J., Mohamed, S., Battaglia, P., Lam, R., & Willson, M. (2025). *Probabilistic weather forecasting with machine learning*. **Nature**, **637**, 84–90.
<https://www.nature.com/articles/s41586-024-08252-9>
- 2- Zhang, H., Liu, Y., Zhang, C., & Li, N. (2025). *Machine Learning Methods for Weather Forecasting: A Survey*. **Atmosphere**, **16**(1), 82.
<https://doi.org/10.3390/atmos16010082>
- 3- Şevgin, F. (2025). *Machine Learning-Based Temperature Forecasting for Sustainable Climate Change Adaptation and Mitigation*. *Sustainability*, **17**(5), 1812.
<https://doi.org/10.3390/su17051812>
- 4- Pasche, O. C., Sanchez-Gonzalez, A., Alet, F., Andersson, T. R., El-Kadi, A., Masters, D., Ewalds, T., Stott, J., Mohamed, S., Battaglia, P., Lam, R., & Willson, M. (2025). Validating deep learning weather forecast models on recent high-impact extreme events. *Artificial Intelligence for the Earth Systems*, **4**(1), e240033.
<https://doi.org/10.1175/AIES-D-24-0033.1>
- 5- Allen, A., Markou, S., Tebbutt, W., Requeima, J., Bruinsma, W. P., Andersson, T. R., Herzog, M., Lane, N. D., Chantry, M., Hosking, J. S., & Turner, R. E. (2025). *End-to-end data-driven weather prediction*. **Nature**, **641**, 1172–1179.
<https://doi.org/10.1038/s41586-025-08897-0>

- 6-** Bonavita, M. (2024). *On some limitations of current machine learning weather prediction models*. **Geophysical Research Letters**, 51(12), e2023GL107377.
<https://doi.org/10.1029/2023GL107377>
- 7-** U.S. Department of Education, Office of Educational Technology. (2023). *Artificial Intelligence and the Future of Teaching and Learning: Insights and Recommendations*. Washington, DC: U.S. Department of Education. Retrieved from
<https://www.ed.gov/sites/ed/files/documents/ai-report/ai-report.pdf>
- 8-** Choi, R. Y., Coyner, A. S., Kalpathy-Cramer, J., Chiang, M. F., & Campbell, J. P. (2020). *Introduction to machine learning, neural networks, and deep learning*. *Translational Vision Science & Technology*, 9(2), Article 14.
<https://pmc.ncbi.nlm.nih.gov/articles/PMC7347027/>
- 9-** Brown, S. (2021, April 21). Machine learning, explained. MIT Sloan School of Management. Retrieved from
<https://mitsloan.mit.edu/ideas-made-to-matter/machine-learning-explained>
- 10-** Sarker, I. H. (2021). Machine Learning: Algorithms, Real-World Applications and Research Directions. *SN Computer Science*, 2, Article 160.
<https://link.springer.com/article/10.1007/s42979-021-00592-x>
- 11-** OpenStax. (n.d.). Introduction to Python Programming. OpenStax. Retrieved from

https://assets.openstax.org/oscms-prodcms/media/documents/Introduction_to_Python_Programming_-_WEB.pdf

12- Weisberg, S. (2014). Applied Linear Regression (4th ed.). Wiley.

Retrieved from

<https://www.stat.purdue.edu/~qfsong/teaching/525/book/Weisberg-Applied-Linear-Regression-Wiley.pdf>